

(RAG) الدليل الشامل لمقاييس تقييم الذكاء الاصطناعي Evaluation Guide)

استخدمناه في مشروعنا، الفائدة منه، والنتيجة التي استفدناها من تطبيقه على النظام (Metric) هذا الملف يشرح بالتفصيل كل مصطلح تقييم الطبّي الخاص بنا.

الكلاسيكية؟ (FP, FN, TP, TN) أولاً: لماذا لا نستخدم

(False Positives / False Negatives) في أنظمة التصنيف العادية (مثل معرفة هل الصورة قطة أم كلب)، نستخدم مصطلحات الإيجابي والسلبي الكاذب.

نحن نبحث في قاعدة بيانات تحتوي على 10,000 فقرة، (Information Retrieval - RAG) لكن في أنظمة البحث والاسترجاع (Ground Truth) والمريض يسأل سؤالاً له إجابة واحدة صحيحة فقط.

- لأنها فقرات أخرى مفيدة ربما لكنها False Positives و 9 True Positive سيكون لدينا 1 (Top-K=10) إذا جلبنا 10 فقرات True Negatives و 9,990، (ليست الإجابة النموذجية).
- العادي هنا سيعطيك دائماً 10% (1 من أصل 10) Precision حساب η .
- "التقييم" الترتيب وليس فقط "التصنيف" @K ومحركات البحث مثل جوجل، نستخدم مقاييس مخصصة مثل RAG لذلك، في عالم الـ.

(Retrieval Metrics) ثانياً: مقاييس الاسترجاع

1. معدل الإصابة (Hit Rate @K)

- (Top-10 نحن استخدمنا) نتيجة تم جلبها من قاعدة البيانات؟ K ضمن أول (Ground Truth) ما هو؟ هل ظهرت الفقرة الصحيحة.
- صفرًا، فالذكاء Hit Rate يعمل أم أنه "أعمى" ولا يجد الإجابة. إذا كان الـ (Vector DB) فائدته: يخبرنا هل محرك البحث الاصطناعي سيهلوس حتماً.
- ماذا استفدنا؟ تأكدنا أن نظامنا قوي جداً بنسبة نجاح تفوق 92%، مما يعني أن المعلومة لا تضيع أبداً.

2. دقة البحث (Precision @K)

- ما هو؟ من بين الـ 10 فقرات التي جلبناها، كم فقرة كانت صحيحة تماماً؟
- % هو Precision 10 إذا جلبنا 10 فقرات وكانت واحدة فقط مفيدة، فالـ (Noise) فائدته: يخبرنا بكمية "الضوضاء".

- **Reranker** يجلب ضوضاء كثيرة، ولذلك قمنا بابتكار خطوة الـ **Vector Search** ماذا استفدنا؟ أدركنا أن الـ الضوضاء.

3. متوسط الرتبة العكسية (MRR - Mean Reciprocal Rank)

- **ما هو؟** يقيس "أين ظهرت" الإجابة الصحيحة. إذا ظهرت في المركز الأول، تأخذ 1.0. إذا ظهرت في المركز الثاني، تأخذ 0.5. إذا ظهرت في المركز الثالث، تأخذ 0.33.
- سيضطر لقراءة نصوص كثيرة قبل أن يجد الإجابة، أم أنها في الصدارة؟ (LLM أو الـ) **فائدته:** يخبرنا هل المستخدم
- (MRR 0.83) **ماذا استفدنا؟** تأكدنا أن الأدوية تُسترجع غالباً في المركز الأول.

4. جودة الترتيب (NDCG - Normalized Discounted Cumulative Gain)

- **ما هو؟** مقياس معقد قليلاً يعطي وزناً أكبر للنتائج الصحيحة التي تظهر في الأعلى، ويعاقب النظام إذا جلب نتائج صحيحة ولكن في ذيل القائمة.
- **Reranker فائدته:** التقييم المثالي للـ.
- كان يدمر ترتيب الأدوية المصرية، وبناءً عليه اتخذنا (MS-MARCO) الأجنبي **Reranker** ماذا استفدنا؟ ساعدنا في اكتشاف أن الـ (Bypass) القرار المعماري بفصله.

(Generation & Safety Metrics) ثالثاً: مقاييس التوليد والأمان الطبي

5. دقة الإجابة (Answer Relevance)

- **ما هو؟** يقيس هل الإجابة النهائية التي نطق بها الموديل ترد فعلاً على سؤال المريض؟ أم أن الموديل يتحدث في وادٍ آخر؟
- **فائدته:** يحمينا من الإجابات "المراوغة".
- **ليعمل كطبيب بشري (LLM-as-a-Judge) العقيمة، إلى استخدام (Cosine Similarity) ماذا استفدنا؟** قمنا بتغيير طريقة قياسه من يقيم الإجابة من 1 إلى 5. وحصل نظامنا على 4.8 / 5.0.

6. الأمان والموثوقية (Faithfulness / RAGAS)

- **أم استند 100% (Hallucination) ما هو؟** يقيس مدى ارتباط كلام الموديل بالفقرات التي جلبها. هل الموديل "اخترع" معلومة من رأسه للمرجع؟
- **فائدته:** أهم مقياس طبي **على الإطلاق!** لا مجال للتأليف في الطب.
- **الخاص بنا مكتوب بعقوبة ويجبر الموديل على الالتزام System Prompt ماذا استفدنا؟** حقق نظامنا 100% (1.0)، مما يثبت أن الـ الحرفي بالمصادر.

7. مناعة الضوضاء (Noise Robustness)

- نقوم بحقن النظام بقرارات كاذبة ومضللة (مثلاً: "البندول يعالج السرطان") ونرى هل سينخدع. (Adversarial) ما هو؟ اختبار هجومي بها أم لا.
- **فائدته:** يضمن أن النظام لا يتبع أي هراء يُقدم له، بل يفلتر المعلومات.
- **ماذا استفدنا؟** حقق نظامنا 100% نجاح، الموديل تجاهل كل الضوضاء الكاذبة وركز فقط على الحقائق.

:ملخص الإنجاز

لم نَقم فقط ببرمجة شات بوت، بل قمنا بـ (Google و OpenAI في العالم كـ AI التي تستخدمها كبرى شركات الـ) باستخدام هذه المقاييس. هندسة نظام طبي آمن، ومختبر، ومثبت كفاءته بالأرقام الرياضية الدقيقة.